GUIA DE MODELOS E CUSTOS

Revisão manual de código • GitHub Copilot vs. contratação direta por API

Versão revisada em 26 de outubro de 2026

O que foi melhorado

O PDF original misturava nomes de modelos, classificações e preços sem indicar a fonte nem distinguir o custo da API do mecanismo de cobrança do Copilot. Esta versão organiza os modelos por fornecedor, indica se são proprietários ou open source, compara tarifas por milhão de tokens e explica como interpretar o custo no Copilot.

Leitura rápida

Para revisão de rotina e baixo custo	Comece por um modelo leve, como GPT-6 Luna ou Claude Haiku 5.5; use-o para triagem, explicação de funções e testes iniciais.
Para bugs complexos	Use um modelo mais capaz, como Claude Sonnet 5.5 ou GPT-6 Sol, quando a tarefa exigir raciocínio multi-arquivo, análise de concorrência ou investigação de regressões.
Para contexto muito grande	Confira o tier de contexto longo: a tarifa pode subir quando a entrada ultrapassa o limite definido pelo fornecedor/Copilot.
Open source	Os modelos de peso aberto podem permitir execução local ou hospedagem própria, mas isso não significa custo zero: hardware, energia e operação também custam.

Importante: o Copilot não é simplesmente “a API com outro nome”. Planos individuais incluem uma franquia de AI Credits; quando há cobrança por uso adicional, o GitHub converte o consumo em créditos. 1 AI Credit = US$ 0,01. Portanto, o custo efetivo para quem já paga a assinatura depende da franquia incluída, do uso acumulado e do modelo escolhido.

1. Tabela comparativa detalhada

Preços de referência em USD por 1 milhão de tokens, sem impostos. Para facilitar a comparação, a coluna “Copilot” mostra a tarifa de tokens publicada pelo GitHub em AI Credits convertida para dólares (1 crédito = US$ 0,01). O custo efetivo pode ser coberto pela franquia da assinatura.

Modelo	Empresa	Licença / acesso	Perfil	API entrada (US$/1M)	API saída (US$/1M)	Copilot entrada (US$/1M eq.)	Copilot saída (US$/1M eq.)	Uso sugerido
GPT-6 Luna	OpenAI	Proprietário	Leve / custo baixo	$0.10	$0.50	$0.10	$0.50	Triagem, perguntas rápidas, testes e revisões simples. Contexto longo pode ter tarifa maior.
GPT-6 Sol	OpenAI	Proprietário	Potente	$2.00	$10.00	$2.00	$10.00	Revisão de lógica complexa, bugs difíceis e análise multi-arquivo.
GPT-6 Astra	OpenAI	Proprietário	Potente / premium	$10.00	$50.00	$10.00	$50.00	Tarefas difíceis; alto custo. Use quando a qualidade adicional justificar.
GPT-6.1 Terra	OpenAI	Proprietário	Versátil	$1.00	$5.00	$1.00	$5.00	Equilíbrio entre capacidade e preço; confirme o tier exato disponível.
GPT-5.3-Codex	OpenAI	Proprietário	Especializado em código	$1.75	$14.00	$1.75	$14.00	Implementação e tarefas de programação; saída relativamente cara.
Claude Haiku 5.5	Anthropic	Proprietário	Leve	$0.10	$0.50	$0.10	$0.50	Explicações, revisão preliminar e tarefas simples; acima de 100K tokens, tarifa longa maior.
Claude Sonnet 5.5	Anthropic	Proprietário	Versátil / recomendado	$2.00	$10.00	$2.00	$10.00	Boa opção geral para revisão cuidadosa e investigação de bugs.
Claude Opus 5.5	Anthropic	Proprietário	Premium	$4.00	$20.00	$4.00	$20.00	Problemas de alta complexidade; custo superior ao Sonnet.
Gemini 3.8 Flash	Google	Proprietário	Flash / leve	$0.75	$3.75	$0.75	$3.75	Respostas rápidas e tarefas frequentes; valide disponibilidade no seu plano/IDE.

Tarifas e disponibilidade são dinâmicas. Os preços da API direta foram cotejados com as páginas oficiais dos fornecedores; os valores Copilot equivalentes foram cotejados com a tabela oficial de modelos e preços do GitHub. Quando a tarifa do Copilot e a da API coincidem, isso não significa que a assinatura do Copilot seja cobrada token a token desde o primeiro uso.

2. Como entender o custo por token

Os valores por milhão são mais fáceis de ler do que frações minúsculas por token. Para obter o preço unitário, divida a tarifa por 1.000.000.

GPT-6 Luna — US$ 0,10 / US$ 0,50 por 1M	$0,00000010	$0,00000050	US$ 0,015
Claude Sonnet 5.5 — US$ 2 / US$ 10 por 1M	$0,00000200	$0,00001000	US$ 0,30
GPT-6 Astra — US$ 10 / US$ 50 por 1M	$0,00001000	$0,00005000	US$ 1,50

Fórmula aproximada

Custo = (tokens de entrada ÷ 1.000.000 × tarifa de entrada) + (tokens de saída ÷ 1.000.000 × tarifa de saída). Tokens em cache, gravação de cache, contexto longo, ferramentas e outros recursos podem ter tarifas próprias.

API direta vs. Copilot: o que realmente muda?

Contratação direta (API)	GitHub Copilot
Você cria uma conta de API com o fornecedor e paga pelo consumo medido, normalmente por token. A assinatura de ChatGPT/Claude/Gemini para uso no aplicativo não deve ser presumida como crédito de API.	Você paga o plano Copilot e recebe uma franquia mensal de AI Credits conforme o plano. O consumo de modelos é contabilizado em créditos; 1 AI Credit equivale a US$ 0,01. Ao exceder a franquia, pode haver cobrança adicional conforme a configuração da conta.
Mais controle sobre integração, logs, limites, cache e escolha do provedor. Exige implementação e gestão de chaves.	Integração pronta na IDE e experiência unificada. Disponibilidade, limites e cobrança dependem do plano, políticas do GitHub e modelo selecionado.

Atenção: no Copilot, o custo efetivo pode não ser simplesmente “tokens × preço da tabela” se o uso estiver dentro da franquia. Também pode variar com tokens em cache, contexto longo e funcionalidades que executam várias etapas. Para comparar financeiramente, use o consumo real exibido no painel da conta.

3. Propriedade, open source e recomendações

Os modelos destacados na tabela são modelos proprietários oferecidos por empresas específicas. “Disponível no Copilot” não significa “open source”, e acesso pela API não implica permissão para baixar os pesos do modelo.

Família	Empresa	Tipo	O que isso significa
GPT-6 / GPT-5.3-Codex	OpenAI	Proprietário	Acesso por serviços oficiais; pesos não são publicados como open source para esses modelos.
Claude Haiku / Sonnet / Opus	Anthropic	Proprietário	Acesso por Claude/API e plataformas parceiras; não é um modelo de pesos abertos.
Gemini Flash	Google	Proprietário	Acesso por Gemini API e produtos Google; não confundir com a família Gemma, que possui modelos abertos.
Modelos de pesos abertos (ex.: Qwen, DeepSeek ou alguns modelos Gemma)	Alibaba / DeepSeek / Google, conforme o modelo	Varia por modelo e licença	Podem permitir download e execução própria, mas é necessário verificar a licença exata, restrições de uso e requisitos de hardware.

Fluxo de trabalho recomendado para code review

1. Triagem	Modelo leve: peça uma lista de riscos, pontos suspeitos e testes ausentes; limite o escopo aos arquivos relevantes.
2. Investigação	Modelo versátil/potente: forneça contexto, comportamento esperado, diff e evidências. Peça hipóteses verificáveis, não apenas uma reescrita.
3. Verificação	Peça referências a arquivo/linha, cenário de reprodução e teste que falharia antes da correção. Confirme as conclusões executando testes e analisando o código.
4. Controle de custo	Evite reenviar repositórios inteiros sem necessidade. Reutilize contexto quando for útil, mas não presuma que trocar de modelo sempre invalida todo cache: o comportamento depende do produto e da implementação.

4. Fontes e notas metodológicas

As tarifas abaixo são referências públicas consultadas em 26/10/2026. O GitHub pode alterar modelos, preços, franquias e disponibilidade; confirme antes de tomar decisões de orçamento.

GitHub Docs — Modelos e preços para GitHub Copilot

https://docs.github.com/pt/copilot/reference/copilot-billing/models-and-pricing
Fonte para tarifas por token no Copilot, tiers de contexto e equivalência em AI Credits.

GitHub Docs — Cobrança baseada em uso para indivíduos

https://docs.github.com/en/copilot/concepts/billing-and-usage/individuals/billing
Explica a franquia mensal de créditos, uso adicional e a equivalência de 1 AI Credit = US$ 0,01.

OpenAI API — Pricing

https://developers.openai.com/api/docs/pricing
Referência para preços diretos da API OpenAI.

Anthropic — Claude pricing

https://docs.anthropic.com/en/docs/about-claude/pricing
Referência oficial de tarifas da API Claude; conferir a página atual para modelos recentes.

Google AI for Developers — Gemini API pricing

https://ai.google.dev/gemini-api/docs/pricing?hl=pt-br
Referência oficial de preços da Gemini API.

Limitações e transparência

• Valores arredondados e expressos em USD por 1 milhão de tokens; não incluem impostos, câmbio, chamadas de ferramentas, execução de agentes ou custos de infraestrutura.
• As tarifas podem diferir entre provedores e GitHub em determinados modelos/tier. A tabela usa a tarifa publicada para os modelos selecionados na consulta e não deve ser interpretada como cotação contratual.
• Para alguns modelos recentes, a disponibilidade e os preços diretos podem variar por região, endpoint ou modalidade. Se não houver preço oficial direto verificável para um modelo/tier específico, não extrapole o valor do Copilot como garantia de tarifa da API.
• O custo real de uma revisão depende da proporção entre entrada e saída, quantidade de contexto repetido, cache, número de chamadas e uso de contexto longo.

Recomendação final: para comparar de forma justa, registre algumas revisões reais (tokens de entrada, saída, cache e modelo) e calcule o custo por revisão. Uma tarifa por milhão isolada não revela quanto custa uma sessão longa na IDE.