Guia de Estratégia e Custos: Revisão Manual de Código

Este documento consolida as principais recomendações estratégicas e análises de custo-benefício para desenvolvedores que realizam a **revisão manual de código (Code Review)** utilizando o menu de modelos do GitHub Copilot / IDEs. Fora do ecossistema de automação pesada ("vibe coding"), o foco é maximizar a precisão interpretativa e a detecção de falhas sem gerar despesas desnecessárias de tokens.

> **⚠️ Regra de Ouro do Copilot: O Impacto da Troca de Modelos**
>
> Ao alternar entre modelos no meio de uma mesma sessão de chat, todo o **Prompt Cache** (memória temporária que barateia e acelera as requisições) é invalidado. O histórico é repassado para o novo modelo, gerando uma leitura fria do zero. Isso resulta em maior lentidão na primeira resposta e em um aumento significativo no consumo e custos de tokens.

Análise de Custo-Benefício dos Modelos Recomendados

Modelo	Classificação para Revisão	Custo de Entrada (1M)	Custo de Saída (1M)	Ponto Forte na Revisão Manual
Claude Sonnet 5.5	RECOMENDADO	US$ 3,00	US$ 15,00	Entrega raciocínio cirúrgico para caçar bugs complexos e refatorar sem o preço absurdo de modelos ultra.
GPT-6 Luna	EVAL_ECONÔMICA	US$ 0,10	US$ 0,50	Melhor opção se você precisar injetar dezenas de arquivos pesados abertos na IDE ao mesmo tempo. Mantém custo fixo até 272K.
Claude Haiku 5.5	Alternativa Leve	US$ 0,10	US$ 0,50	Equivalente ao Luna em agilidade e preço padrão, mas fica mais caro em contextos acima de 100K tokens.
Kimi K3 / Grok 4.7	EVITAR NESTE CASO	Variável (Alto)	Variável (Alto)	São modelos de raciocínio profundo voltados a criar soluções do zero. Gastam tempo e dinheiro demais apenas para analisar o que já existe.

Diretrizes Práticas para Revisão Manual Eficiente

- **Foco Qualitativo Inicial:** Sempre inicie revisões lógicas complexas de trechos, métodos ou arquivos específicos utilizando o **Claude Sonnet 5.5**. A capacidade interpretativa dele reduz o tempo de revisão humana.
- **Transição por Volume (Pivot para o GPT-6 Luna):** Se a revisão exigir a leitura de repositórios inteiros, arquivos legados imensos ou logs extensos na mesma sessão, alterne para o **GPT-6 Luna** para blindar seu orçamento de tokens.
- **Gerenciamento de Contexto Limpo:** Em vez de trocar de modelo na mesma janela (o que destrói o cache), abra uma nova aba de chat limpa na IDE ao mudar do Sonnet para o Luna. Cole apenas o código estritamente necessário.
- **Evite Modelos "Flash":** Modelos como o Gemini 3.8 Flash ou MAI-Code-1.1-Flash priorizam velocidade pura em vez de profundidade cognitiva. Eles frequentemente deixam passar vulnerabilidades de segurança ou erros sutis de concorrência.